

Aluno: Felipe Trigueiro Angelo - 210479

Problema 3 - AD: variáveis Teóricas

01.

$X \backslash Y$	$Y=0$	$Y=3$
$X=0$	$1/6$	$3/8$
$X=3$	$1/8$	$1/3$

$$a) P(X) = \begin{cases} 1/6 + 3/8 & ; X=0 \\ 1/8 + 1/3 & , X=3 \end{cases} = \begin{cases} 13/24 & , X=0 \\ 11/24 & , X=3 \end{cases}$$

$$P(Y) = \begin{cases} 1/6 + 1/8 & , Y=0 \\ 3/8 + 1/3 & , Y=3 \end{cases} = \begin{cases} 7/24 & ; Y=0 \\ 17/24 & , Y=3 \end{cases}$$

$$b) P(X=0 | Y=0) = \frac{P(X=0 \cap Y=0)}{P(Y=0)} = \frac{1/6}{7/24} = \frac{4}{7}$$

$$c) E(X) = 0 \cdot \frac{13}{24} + \frac{11}{24} = \frac{11}{24}$$

$$E(Y) = 0 \cdot \frac{7}{24} + \frac{17}{24} = \frac{17}{24}$$

$$d) P(X=0)P(Y=0) = \frac{13}{24} \cdot \frac{7}{24} = \frac{91}{576} \neq P(X=0, Y=0)$$

$$P(X=1)P(Y=0) = \frac{11}{24} \cdot \frac{7}{24} = \frac{77}{576} \neq P(X=1, Y=0)$$



$$P(x=0)P(y=2) = \frac{13}{24} \cdot \frac{17}{24} = \frac{221}{576} \neq P(x=0, y=2)$$

$$P(x=2)P(y=0) = \frac{11}{24} \cdot \frac{17}{24} = \frac{187}{576} \neq P(x=2, y=0)$$

Also  $\rightarrow$  Independence is not satisfied!!

02.

$X \setminus Y$	$Y=0$	$Y=1$
$X=0$	0	1/4
$X=1$	3/8	3/8

$$\begin{aligned} a) H(X) &= -[P(X=0) \log_2 P(X=0) + P(X=1) \log_2 P(X=1)] \\ &= -\left[\frac{1}{4} \log_2 \frac{1}{4} + \frac{6}{8} \log_2 \frac{6}{8}\right] = 0.8113 \text{ bits} \end{aligned}$$

$$\begin{aligned} H(Y) &= -[P(Y=0) \log_2 P(Y=0) + P(Y=1) \log_2 P(Y=1)] \\ &= -\left[\frac{3}{8} \log_2 \frac{3}{8} + \frac{5}{8} \log_2 \frac{5}{8}\right] = 0.7916 \text{ bits} \end{aligned}$$

$$H(X, Y) = -\left[\frac{1}{4} \log_2 \frac{1}{4} + \frac{3}{8} \log_2 \frac{3}{8} + \frac{3}{8} \log_2 \frac{3}{8}\right] = 1.5613 \text{ bits}$$

$$b) H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

$$H(X|Y) = H(X, Y) - H(Y) = 1.5613 - 0.7916 = 0.7697 \text{ bits}$$

$$H(Y|X) = H(X, Y) - H(X) = 1.5613 - 0.8113 = 0.75 \text{ bits}$$


$$c) I(X, Y) = H(X) - H(X|Y) = 0.8113 - 0.7697 = 0.0416 \text{ bits}$$



03 Classificação 2 classes  $C_1$  e  $C_2$  com um único atributo.

a)  $C_1 \sim \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x+1)^2}{2}\right]$

$C_2 \sim \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right]$



Para cada  $x$  podemos encontrar o valor de  $x$  para o qual, sendo utilizado o atributo por máximo de verossimilhança.

Para o caso em questão, o atributo  $P(x, \phi)$  será máximo quando  $x$  estiver na classe  $\phi$  Assim:

$$L(x, C_1) > L(x, C_2) \rightarrow x: C_1$$

$$L(x, C_1) < L(x, C_2) \rightarrow x: C_2$$

Como  $L(x, C_i) = P(x|C_i)$ , temos:

$$L(x, C_1) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x+1)^2}{2}\right]$$

$$L(x, C_2) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right]$$

Equando  $L(x, C_1) = L(x, C_2)$

$$L(x, C_1) = L(x, C_2) \rightarrow (x+1)^2 = (x-1)^2$$

$$x^2 + 2x + 1 = x^2 - 2x + 1 \rightarrow \boxed{x = 0}$$



Assim, temos as margens de densidade

$$R(x) = \begin{cases} C_1, & x < 0 \\ C_2, & x > 0 \end{cases}$$

b)  $P(C_1) = 0,7$  e  $P(C_2) = 0,3$

- Equivalência:

$$\frac{0,7}{\sqrt{2\pi}} \exp\left[-\frac{(x+1)^2}{2}\right] = \frac{0,3}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right]$$

$$\frac{\ln(7/3)}{2} - \frac{(x+1)^2}{2} = -\frac{(x-1)^2}{2}$$

$$\ln(7/3) - x^2 - 2x + 1 = -x^2 + 2x - 1$$

$$x = \frac{\ln(7/3)}{2} \approx 0,85$$

Dado o gráfico da densidade, temos

$$R(x) = \begin{cases} C_1, & x < 0,85 \\ C_2, & x \geq 0,85 \end{cases}$$

# EFC1 - Regressão Linear

Felippe Trigueiro Angelo - RA: 210479

26 de Setembro de 2019

## Parte II - Atividade computacional

### a) Regressão Linear utilizando a Equação Normal

No presente exercício será construído um preditor linear, onde com base em  $K$  amostras passadas será previsto o valor no instante de tempo imediatamente posterior. Assim, o vetor  $x(n)$  de entradas será constituído por  $x(n) = [x(n-1) \dots x(n-K)]$ . Portanto, para cada valor de  $x(n)$  será calculado um valor  $y(n)$  correspondente a estimação.

Para este exercício será utilizado o conjunto de dados correspondente a temperatura mínima da cidade de Melbourne nos anos de 1981 até 1990.

O conjunto de dados de temperatura está disposto em 3650 linhas e 2 colunas, onde cada linha representa uma amostra de temperatura. As colunas correspondem às datas e as temperaturas mínimas. O conjunto de dados não contém ausência de nenhum valor.

Antes da realização do treinamento, o conjunto de dados foi separado em duas partes, o conjunto de treinamento e o conjunto de teste. O conjunto de treinamento é formado pelas temperaturas correspondentes aos anos de 1981 até 1989. Assim, o conjunto de teste é formado pelas temperaturas referentes ao ano de 1990.

Para o treinamento da primeira parte do exercício foi avaliado o algoritmo de regressão linear. A sua implementação foi realizada utilizando a equação normal, assim, a minimização da soma dos mínimos quadrados (SSD) foi utilizada como métrica. Não foi realizada a normalização nem a regularização dos dados.

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_N \end{bmatrix} \quad \Phi = \Phi(\mathbf{X}) = \begin{bmatrix} 1 & \mathbf{x}_1 \\ 1 & \mathbf{x}_2 \\ & \vdots \\ 1 & \mathbf{x}_N \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

Modelo:

$$\hat{\mathbf{y}} = \hat{\mathbf{y}}(\mathbf{X}) = \Phi \mathbf{w} \quad (1)$$

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y} \quad (2)$$

Para a seleção da quantidades de amostras passadas (K) foi utilizado o esquema de validação cruzada utilizando a abordagem k-fold. Nesse caso foi utilizado um valor de k igual a 4, correspondendo assim a 4 divisões do conjunto de treinamento.

Para avaliar qual o melhor valor de K foi calculada a raiz da soma dos quadrados (RMSE) no conjunto de validação, para os valores de K no intervalo de 1 a 30. Assim, o valor de K a ser escolhido corresponde a quantidade de amostras passadas que resulta no menor valor de erro. O gráfico correspondente ao desempenho do erro RMS com relação ao número de amostras passadas (K) pode ser visto na Figura 1. No processo de validação cruzada, pode ser visto que o menor valor de K (2.4291) corresponde a 18 amostras passadas.

Por fim, o modelo foi avaliado no conjunto de testes e a comparação pode ser vista no gráfico da Figura 2. O erro RMS avaliado no conjunto de testes foi de 4.95.

## b) Regressão Linear utilizando Ridge Regression

Na segunda parte do exercício, o conjunto de amostras utilizadas para o treinamento foi obtido por meio da equação  $\mathbf{X}'(n) = \tanh(\mathbf{w}_k \mathbf{x}(n))$ , onde os coeficientes  $\mathbf{w}$  são obtidos aleatoriamente por meio de uma distribuição normal.

Na formação do conjunto de treinamento foram avaliados amostras com tamanhos (T) que variam de 1 até 100. Assim, para cada valor de T são obtidos, T vetores  $\mathbf{w}$ . Além disso, cada vetor  $\mathbf{w}$  tinha tamanho 5, assim o algoritmo de aprendizado recebe como entrada um conjunto de vetores contendo 5 amostras passadas.




Figura 1: Desempenho do erro RMS com relação ao número de amostras passadas. O desempenho foi obtido por meio do algoritmo de regressão linear sem regularização. O menor valor de erro foi 2.4291 e foi obtido para K igual a 18.




Figura 2: Comparação dos dados do conjunto de teste (Target) com os dados obtidos na predição.

A função tangente hiperbólico possui um comportamento aproximadamente linear nas regiões de -1 a 1, e um comportamento não linear nas outras regiões, juntamente com uma saturação para valores maiores que 3 (ou menores que -3). Assim, para evitar que o conjunto de dados seja composto de valores saturados, se faz necessário ajustar a escala dos valores  $x(n)$  bem como dos valores dos coeficientes  $w$ . Para o presente exercício, os valores de  $w$  foram obtidos na faixa entre 0 e 0.45 e os valores de  $x(n)$  foram normalizados para a faixa entre 0 e 1. Assim, os valores de  $x'$  estarão na faixa de 0 e 2.25.

Como modelo de treinamento foi utilizado a regressão linear juntamente com a regularização com ridge regression. Assim, o vetor de coeficientes pode ser obtido por meio da equação normal abaixo. Para a regularização foram inicialmente testados valores de  $\lambda$  entre 0 e 1 com um passo de 0.01. Como foi observado que para um dado  $T$ , os valores de Erro RMS aumentavam, o treinamento foi realizado apenas para essa faixa.

Para a obtenção dos valores de  $T$  e de  $\lambda$ , foi utilizado a abordagem da validação cruzada  $k$ -fold com um valor de  $k$  igual a 4. Assim, os valores de  $T$  e  $\lambda$  que minimizaram o erro RMS foram utilizados na construção do modelo.

$$\mathbf{w} = (\Phi^T \Phi + \lambda \mathbf{I}')^{-1} \Phi^T \mathbf{y} \quad (3)$$

Para a análise do erro RMS com relação ao tamanho do vetor de entrada ( $T$ ), foi obtido o gráfico do desempenho do erro RMS com relação a  $T$ . Para a sua obtenção, para um dado valor de  $T$  foi calculado a média do erro RMS entre todos os valores de regularização. O resultado pode ser visto na Figura 3.

Além disso, também foi obtido o valor de  $\lambda$  que minimizou o erro RMS para um dado valor de  $T$ . Os valores podem ser vistos na Figura 4.

Fazendo a análise do menor erro RMS obtido para um dado  $T$  e  $\lambda$  no conjunto de validação, foi obtido o valor de 2.4687, obtido para  $T$  igual a 11 e  $\lambda$  igual a 0. Assim, com esses valores em mãos, foi obtido um novo modelo e o seu desempenho foi avaliado no conjunto de teste. A comparação entre os dados de teste e os dados obtidos no modelo pode ser vista na Figura 5. O valor do erro RMS obtido para esse conjunto de dados foi de 5.3753.






Figura 3: Média do erro RMS para os valores de regularização, em função do tamanho do vetor de entrada ( $T$ ).




Figura 4: Fator de regularização ( $\lambda$ ) em função do tamanho do vetor de entrada ( $T$ ).




Figura 5: Comparação dos dados do conjunto de teste (Target) com os dados obtidos na predição por meio dos dados não lineares.